AURA DRIVE | 발표대본 01/20



AURA DRIVE는 눈 감김과 하품을 이미지로 분류하고, 지속 시간을 확인해 운전자에게 경고하는 졸음운전 예방 지원 프로토타입입니다. 높은 내부 점수만 제시하는 대신 직접 촬영한 사진과 외부 데이터로 모델을 검증했습니다. 데이터 수집과 전처리, 모델 비교, 외부 검증, 최종 개발 후보 및 시연 범위를 설명하겠습니다. 사고 예방은 프로젝트의 목표이며 실제 사고 감소 효과를 입증한 것은 아닙니다.

근거: 실제 학습·외부 평가 기록 기반 · 2026.11.09

발표 권장: 22~27분 · 실험 수치의 분모와 조건을 함께 설명



미국 도로교통안전국 NHTSA는 2024년 졸음운전 관련 사고 사망자를 644명으로 제시합니다. 미국 통계이며 우리나라 수치가 아닙니다. 졸음 관련 사고의 정확한 규모를 파악하기 어렵다는 점도 함께 설명합니다. 시속 100킬로미터에서 3초 동안 이동하는 거리는 단순 계산으로 약 83 미터입니다. 이는 실험 결과가 아니라 위험을 설명하기 위한 예시입니다. 따라서 본 프로젝트는 눈 감김과 하품의 시각적 징후를 감지해 경고하는 것을 목표로 합니다. 감지 성능과 실제 사고 감소 효과는 구분합니다.

근거: NHTSA · Drowsy Driving · 미국 2024년 | https://www.nhtsa.gov/risky-driving/drowsy-driving



목표는 눈과 입의 이미지에서 졸음과 관련된 행동을 찾아 경고로 연결하는 것입니다. 눈은 Open과 Closed, 하품은 no_yawn과 yawn의 이진 분류로 나눴습니다. 모델은 정확도뿐 아니라 실제 눈 감김과 하품 중 얼마나 잡았는지를 나타내는 재현율로 비교합니다. 오탐도 함께 살펴 불필요한 경고를 줄이고자 합니다. 현재 확인한 것은 이미지 분류 지표와 앱 연결이며, 시간 단위의 이벤트 성능, 실제 주행 안정성, 사고 감소 효과는 다음 검증 과제입니다.

근거: common.py · 03_yawn_common.py · 클래스 폴더 · 프로젝트 후속 실험 계획 · 아직 검증된 성능 수치가 아님



로컬 원본에는 Closed 726장, Open 726장, 비하품 725장, 하품 723장이 있습니다. 학습 전에 파일을 열 수 있는지, 라벨과 폴더가 맞는지, 중복은 없는지 확인했습니다. 기존 train과 test 폴더 이름을 그대로 신뢰하지 않고 정제 후 다시 나눴습니다. 공개 수집 이미지와 직접 촬영 사진, 이후 외부 평가 자료는 역할을 구분했습니다. 원본 다운로드 페이지와 이용 조건이 완전히 보존되지 않은 자료는 출처 추적의 한계로 남겼으며 임의의 출처 주소를 붙이지 않았습니다. 완전 중복은 해시로 제거하고, 동일 이미지에 상충하는 라벨이 있으면 제외하도록 했습니다. 유사 이미지는 dHash 해밍 거리 5 이하를 기준으로 그룹화해 같은 그룹이 분할을 넘지 않게 했습니다. 이후 약 70 대 15 대 15로 학습·검증·테스트를 나누고 종횡비를 유지한 224 곱하기 224 패딩을 적용했습니다. 눈은 1017·218·217장, 하품은 1016·218·214장입니다. 이는 유사 이미지 단위 분리이지, 모든 사람의 신원이 완전히 분리됐음을 보장하는 것은 아닙니다.

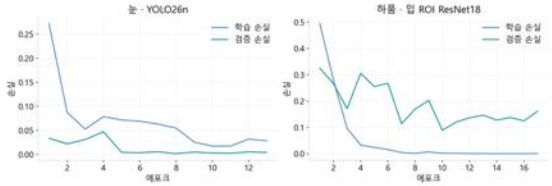
근거: data/raw · data/processed/manifest.csv · 01_audit_data.py · 02_prepare.py · common.py · data/processed/manifest.csv

AURA DRIVE / 실험과 검증

눈: 구조와 계산량이 다른 세 모델을 비교했습니다

내부 테스트 217장 · Closed 102장 / Open 115장

모델	선정 이유	정확도	Closed 재현율
YOLO26n-cls	경량 분류 · 실시간 적용 후보	100%	100%
ResNet18	잔차 구조 · 비교 기준	100%	100%
MobileNetV3-Small	모바일 경량 구조	100%	100%



100%가 곧 실환경 성능은 아닙니다.

분할·촬영 조건 편향 가능성을 의심하고 직접 촬영 및 외부 데이터로 검증했습니다.
이 점수만으로 과적합을 확정하지는 않습니다.

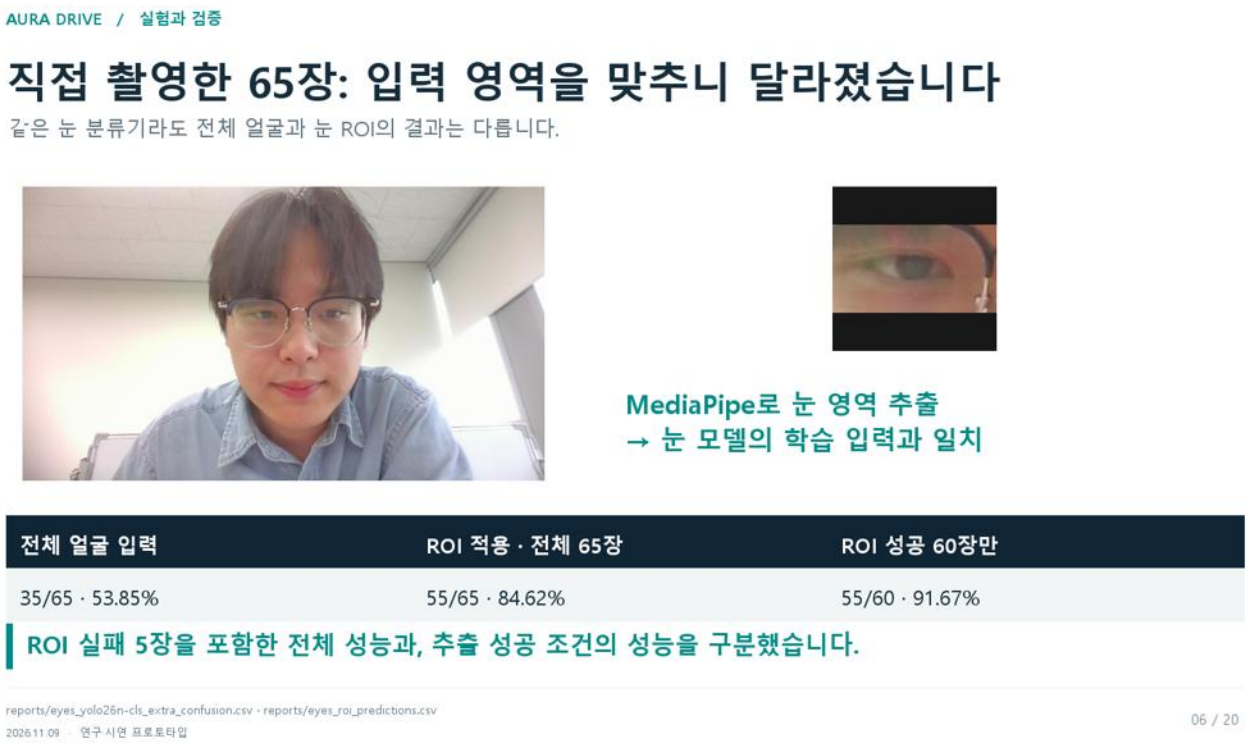
실험별 상세 근거: 근거자료.md 및 기존 37장 slide_manifest.json

2026.11.09 · 연구 시연 프로토타입

05 / 20

YOLO26n-cls는 작은 분류 모델로 로컬 CPU에서도 사용할 수 있는 경량 후보였습니다. ResNet18은 잔차 연결을 쓰는 대표적인 CNN으로 비교 기준을 만들기 좋았습니다. MobileNetV3-Small은 경량 연산을 목표로 한 구조여서 크기와 지연을 비교하기 위해 선택했습니다. 여기서 YOLO는 물체 검출 박스를 학습하는 모델이 아니라 분류 버전입니다. 얼굴과 눈의 위치는 MediaPipe가 찾습니다. 사전학습 가중치를 활용한 전이학습이며 별도의 상용 클라우드 판별 API를 호출한 것은 아닙니다. 그래프는 실제 저장된 에포크별 손실입니다. 눈 YOLO 학습 설정은 최대 25에포크, 배치 16, seed 42, 조기 종료 patience 7입니다. 눈 CNN은 학습 이미지에 좌우 반전과 작은 회전을 적용하고 ImageNet 정규화를 사용했습니다. 하품 ResNet은 입 ROI에 좌우 반전과 약한 색 증강을 사용합니다. 손실이 내려갔다는 사실은 학습이 진행됐다는 근거지만, 새 얼굴과 조명에서 잘 동작한다는 증거까지 되지는 않습니다. 그래서 테스트 다음에 실제 입력과 외부 검증을 추가했습니다. 같은 내부 테스트 217장으로 세 모델을 다시 확인했습니다. Closed 102장과 Open 115장을 모두 맞혀 정확도와 Closed 재현율이 각각 100%였습니다. 이 결과만으로 과적합이라고 단정할 수는 없습니다. 데이터가 쉬웠거나 유사한 촬영 환경이 반복됐거나 학습과 평가의 분포가 비슷했을 가능성도 있습니다. 모델 간 차이가 드러나지 않았으므로 파일 크기와 처리 시간을 함께 보고, 외부 얼굴에서도 같은 결과가 나오는지 확인했습니다. 표의 지연은 단일 분류 처리이며 전체 웹캠 지연이 아닙니다.

근거: 실험별 상세 근거: 근거자료.md 및 기존 37장 slide_manifest.json



눈 패치로 학습한 모델에 얼굴 전체를 넣었더니 65장 중 35장만 맞혀 53.85%였습니다. MediaPipe로 눈 영역을 잘라 넣은 뒤에는 전체 65장 중 55장을 맞혀 84.62%로 올랐습니다. 눈 ROI가 추출된 60장만 보면 55장 정답으로 91.67%입니다. 추출 실패 5장을 제외한 조건부 수치이므로 84.62%와 섞어서 말하지 않습니다. 이 실험은 모델을 새로 학습하기 전에 학습 입력과 실제 입력의 부위와 크기를 맞추는 것이 중요하다는 근거였습니다.

근거: reports/eyes_yolo26n-cls_extra_confusion.csv · reports/eyes_roi_predictions.csv

발표 권장: 22~27분 · 실험 수치의 분모와 조건을 함께 설명

AURA DRIVE / 실험과 검증

외부 눈 평가에서는 내부 100%가 유지되지 않았습니다

데이터마다 촬영 조건·입력 형태·중복 가능성이 달라 평가를 분리했습니다.

외부 데이터	장수	기본 YOLO 정확도	해석
CEW	2,423	79.12%	얼굴에서 눈 ROI 추출
MRL	4,000	98.80%	눈 패치 · 학습 중복 가능성
Simuletic	143	97.20%	소규모 별도 평가



Open → Closed



Open → Closed



Open → Closed

CEW: 실제 Open → 예측 Closed

화장·짙은 경계·흐림·안경테 등의 영향을 관찰했습니다. 사진만으로 원인을 확정하지 않고 개선 가설로 사용했습니다.

reports/{cew,mrl,simuletic}/external_summary.csv · reports/cew/error_audit/pairwise_images.csv

2026.11.09 · 연구 시연 프로토타입

07 / 20

외부 눈 평가는 CEW 2423장, MRL 4000장, Simuletic 143장으로 나눠 수행했습니다. MRL은 이미 잘린 눈 패치이며 학습 원자료와 중복 가능성이 있어 강한 독립 검증으로 해석하지 않았습니다. CEW는 얼굴에서 눈을 추출하는 조건으로, 내부 테스트보다 현실적인 입력 차이를 보여줬습니다. 기본 전처리에서 YOLO 정확도는 79.12%, ResNet은 81.18%, MobileNet은 81.55%였습니다. YOLO의 Closed 재현율은 높았지만 Open을 Closed로 보는 오탐이 많아 후속 전처리 실험을 진행했습니다. 이 사진들은 CEW 오류 감사 기록에 남아 있는 실제 오탐입니다. 정답은 Open인데 기존 YOLO가 Closed로 분류했습니다. 눈 화장, 짙은 눈 주변 색, 낮은 해상도와 흐릿한 경계가 오분류와 함께 관찰됐습니다. 다만 사진만 보고 아이라인이나 주름이 직접 원인이라고 단정할 수는 없습니다. 이러한 관찰을 전처리와 조건별 데이터 보강을 시도하는 가설로 사용했습니다. 오류를 설명하려면 전체 얼굴뿐 아니라 실제 모델에 들어간 눈 ROI도 확인해야 합니다.

근거: reports/{cew,mrl,simuletic}/external_summary.csv · reports/cew/error_audit/pairwise_images.csv

발표 권장: 22~27분 · 실험 수치의 분모와 조건을 함께 설명

AURA DRIVE / 실험과 검증

CLAHE와 임계값을 따로 조정했습니다

같은 가중치를 유지한 입력 전처리와 판정 민감도 실험 · CEW 2,423장



원본 눈 ROI



CLAHE · LAB 밝기 채널 보정

전처리 / Closed 기준	정확도	Closed 재현율	Open 오탐률
RGB / 0.50	79.12%	94.21%	35.09%
CLAHE / 0.50	88.90%	81.12%	3.17%
CLAHE / 0.25 · 선택	88.36%	90.69%	13.48%

0.25는 확률 기준입니다. 가중치 변경이나 눈 감김 지속 시간 2초와 다릅니다.

15_roi_ablation.py · LAB L채널 · clipLimit 2.0 · tileGridSize 4×4 · reports/cew/threshold_analysis/threshold_sweep.csv · CEW 2,423장

2026.11.09 연구 시연 프로토타입

08 / 20

왼쪽과 오른쪽은 같은 눈 ROI의 전처리 전후입니다. RGB 이미지를 LAB 색 공간으로 바꾼 뒤 밝기인 L채널에 CLAHE를 적용하고 다시 RGB로 되돌렸습니다. 극단적인 대비 증폭을 제한하면서 국소 경계를 강조하려는 목적입니다. 이후 224 곱하기 224로 패딩해 기존 분류기에 넣었습니다.

이 단계에서는 모델 가중치를 바꾸지 않았습니다. 전체 CEW 지표가 좋아졌다는 사실과 특정 화장 유형의 오류가 해결됐다는 주장은 서로 다른 내용입니다. 기존 RGB의 정확도는 79.12%이고 Closed 재현율은 94.21%였지만 Open 오탐률이 35.09%로 높았습니다. CLAHE만 적용하면 정확도는 88.90%로 높아지지만 Closed 재현율이 81.12%로 떨어졌습니다. 그래서 눈 감김을 더 잡는 방향으로 확률 기준을 0.25로 낮췄습니다. 정확도는 88.36%, Closed 재현율은 90.69%, Open 오탐률은 13.48%였습니다. 가중치 재학습이 아니라 판정 민감도 조정입니다. CEW를 설정 선택에도 썼으므로 이 결과는 독립 최종 시험 성능이 아닙니다.

근거: 15_roi_ablation.py · LAB L채널 · clipLimit 2.0 · tileGridSize 4×4 · reports/cew/threshold_analysis/threshold_sweep.csv · CEW 2,423장

발표 권장: 22~27분 · 실험 수치의 분모와 조건을 함께 설명

AURA DRIVE / 실험과 검증

화장 조건 보강은 가능성을 확인한 소규모 실험입니다

최종 눈 후보는 원본 YOLO26n + CLAHE + Closed 0.25를 유지





눈 모델 설정	CEW 정확도	Simuletic
원본 + CLAHE / 0.25	88.36%	97.90%
추가 분류층 학습	88.90%	97.20%

보강 데이터의 제한 화장 전·후 각 26장, 주름 459장 · 눈 학습에 쓴 추가 자료는 Open만 확보

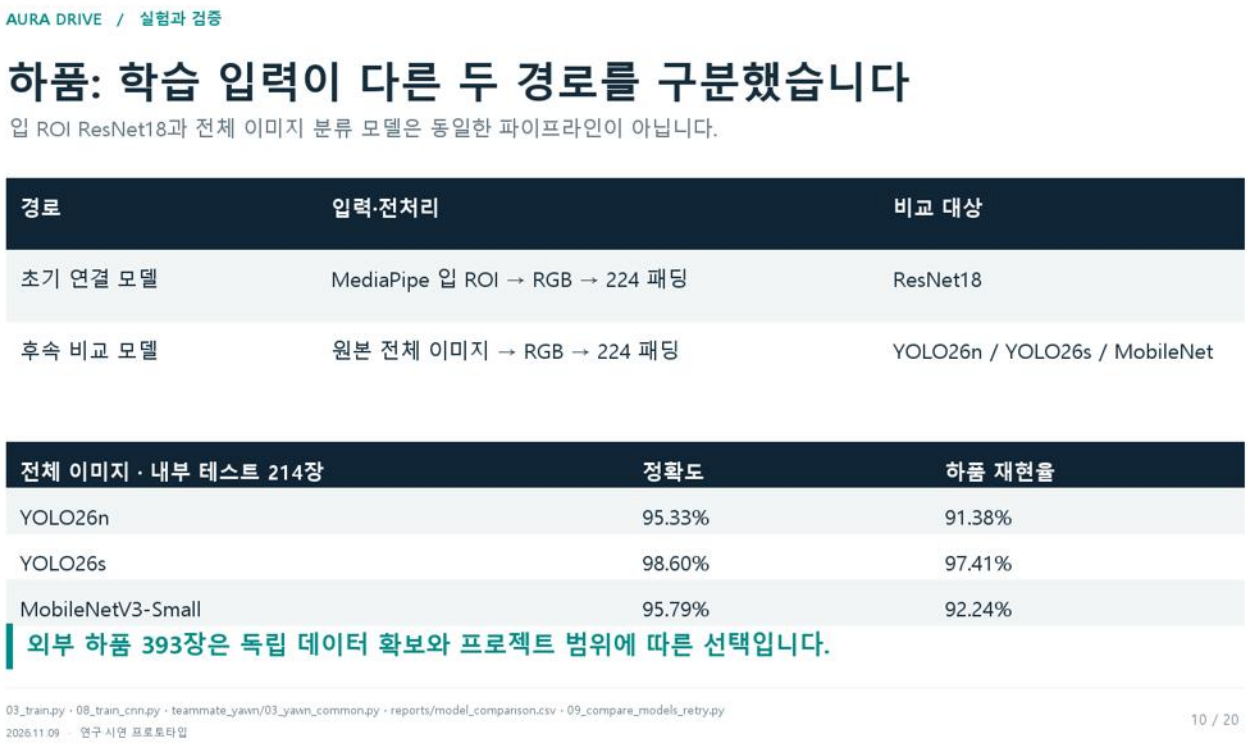
결론 평가셋별 개선이 일관되지 않음 → 원본을 유지하고 조건별 정답 보강 필요

전체 지표 개선과 특정 화장 유형의 해결은 구분해야 합니다.

실험별 상세 근거: 근거자료.md 및 기존 37장 slide_manifest.json
2026.11.09 · 연구 시연 프로토타입 09 / 20

화장 전후 각 26장과 주름 조건 459장을 이미지별로 검토했습니다. 폴더명은 정답 라벨이 아니며 불확실한 사진은 제외했습니다. 눈에서 사용 가능한 추가 데이터는 Open만 있어 Closed 조건까지 학습하거나 평가했다고 말할 수 없습니다. 분류층을 작게 추가 학습했을 때 CEW 정확도는 88.36%에서 88.90%로 올랐지만 Simuletic은 97.90%에서 97.20%로 낮아졌습니다. 따라서 특정 화장의 오류가 해결됐다고 주장하지 않고 원본 모델을 유지했습니다. 추가 양성 사례와 독립적인 사람 검수가 필요합니다.

근거: 실험별 상세 근거: 근거자료.md 및 기존 37장 slide_manifest.json



하품 실험에는 두 경로가 있습니다. 원본 얼굴 이미지 전체를 쓰는 YOLO26n, YOLO26s, MobileNetV3-Small과, MediaPipe로 입 ROI를 잘라 쓰는 팀 ResNet18입니다. 전체 입력은 RGB 이미지를 종횡비를 유지하며 224 곱하기 224로 패딩했습니다. 입 ROI 경로는 입 너비 배율 1.8, 높이 배율 1.35, 중심 보정 0.08로 주변 문맥을 남겼습니다. 모델이 학습한 입력 형태를 유지해야 하므로 두 경로를 같은 전처리라고 부르지 않습니다. 입 ROI ResNet을 먼저 데모에 연결했지만, 최종 선택은 뒤에서 보여드릴 31번 외부 비교를 근거로 다시 결정했습니다. 하품 전체 이미지 경로의 세 모델은 YOLO26n, YOLO26s, MobileNetV3-Small입니다. YOLO26n은 작은 모델의 속도를, YOLO26s는 같은 계열에서 용량을 늘렸을 때의 표현력을, MobileNet은 다른 경량 CNN 구조를 비교하려고 선택했습니다. 내부 정확도는 각각 95.33%, 98.60%, 95.79%였으며 하품 재현율은 91.38%, 97.41%, 92.24%였습니다. 원본 전체 이미지 분할의 214장 결과로, 팀의 입 ROI 성공 212장과 분모가 다릅니다. 내부에서 YOLO26s가 높았다는 것만으로 최종 선택하지 않고, 같은 세 모델을 31번에서 외부 데이터로 재평가했습니다.

근거: 03_train.py · 08_train_cnn.py · teammate_yawn/03_yawn_common.py · reports/model_comparison.csv · 09_compare_models_retry.py

발표 권장: 22~27분 · 실험 수치의 분모와 조건을 함께 설명

AURA DRIVE / 실험과 검증

초기 하품 모델은 외부에서 놓치는 사례가 많았습니다

Roboflow 393장 · 하품 171장 / 비하품 222장 · 입 ROI ResNet18

입력 / 기준	정확도	하품 재현율	의미
RGB / 0.50	65.65%	44.44%	초기 외부 평가
RGB / 0.10	71.50%	66.67%	민감도 상승 · 미검출 57장
흑백 / 0.10	61.83%	67.84%	정확도 손실 · RGB 유지



미검출 57장 중 ROI 실패 22장

색·주름·입 모양을 오류 가설로 관찰
확률 조정만으로는 입력 실패를 해결할 수 없음

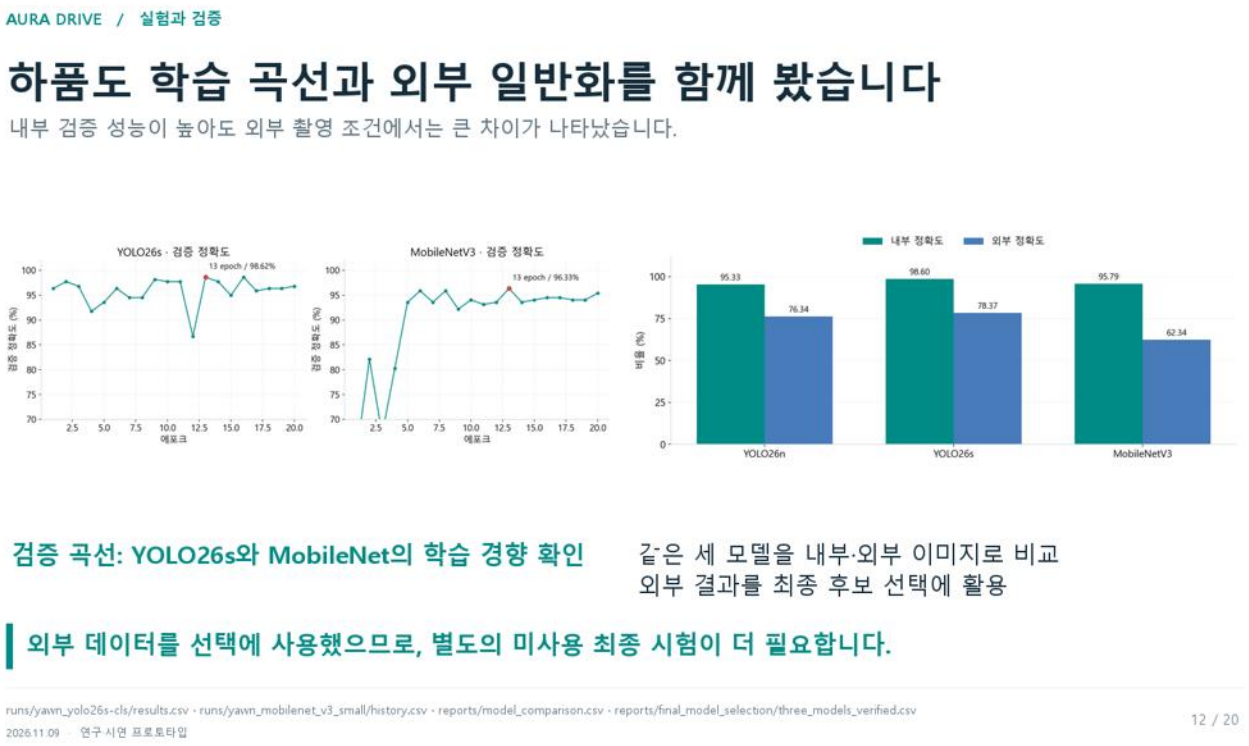
실험별 상세 근거: 근거자료.md 및 기존 37장 slide_manifest.json
2026.11.09 · 연구 시연 프로토타입

11 / 20

초기 입 ROI ResNet18은 내부에서 높은 성능을 보였지만 외부 393장에서 정확도 65.65%, 하품 재현율 44.44%로 낮아졌습니다. RGB를 유지하고 확률 기준을 0.10으로 낮추면 정확도 71.50%, 재현율 66.67%였습니다. 그래도 실제 하품 171장 중 57장을 놓쳤고 그중 22장은 ROI 추출 실패입니다. 흑백 입력의 정확도는 61.83%여서 색 제거가 해결책은 아니었습니다. 입 주변 색이나 주름은 관찰한 조건이며 직접 원인으로 단정하지 않았습니다. 이후 동일 외부 데이터로 전체 이미지 모델 세 개를 비교했습니다.

근거: 실험별 상세 근거: 근거자료.md 및 기존 37장 slide_manifest.json

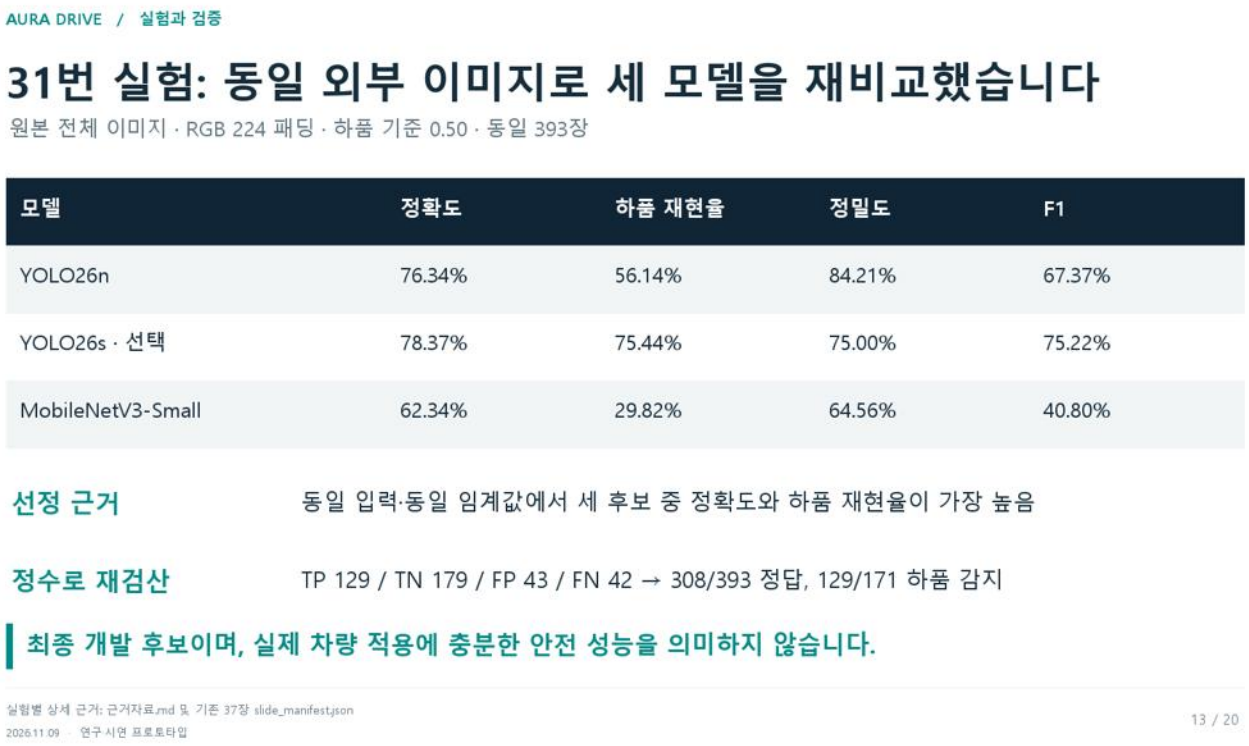
발표 권장: 22~27분 · 실험 수치의 분모와 조건을 함께 설명



이 그래프는 하품 YOLO26s와 MobileNetV3의 실제 저장된 학습 기록입니다. YOLO26s는 최대 25에포크 설정에서 20에포크까지 기록돼 있고, 최고 검증 정확도 98.624%가 처음 나온 에포크는 13입니다. MobileNetV3도 20에포크 기록이며 최고 검증 정확도 96.33%가 처음 나온 시점은 13입니다. 내부 테스트의 YOLO26s 98.60%와 검증 정확도 98.62%는 서로 다른 분모이므로 혼용하지 않습니다. 검증 곡선은 학습 진행과 모델 저장의 근거이고, 외부 성능은 뒤의 독립 출처 이미지로 별도 확인했습니다. 이 그래프만으로 과적합이나 새 운전자 성능을 단정하지 않았습니다. 내부 테스트와 외부 평가의 차이를 세 모델에 대해 나란히 비교했습니다. YOLO26n은 내부 95.33%에서 외부 76.34%, YOLO26s는 98.60%에서 78.37%, MobileNetV3는 95.79%에서 62.34%였습니다. 같은 모델이라도 새로운 출처의 인물과 배경, 화질에서 성능이 낮아졌습니다. 이 차이는 일반화 점검의 필요성을 보여주지만 과적합 하나로 원인을 확정하는 근거는 아닙니다. 이 외부 데이터는 이후 후보 선정에도 사용했으므로 완전히 미사용인 최종 홀드아웃은 아닙니다. 다음 검증에는 새로운 인물과 촬영 조건을 남겨야 합니다.

근거: runs/yawn_yolo26s-cls/results.csv · runs/yawn_mobilenet_v3_small/history.csv · reports/model_comparison.csv · reports/final_model_selection/three_models_verified.csv

발표 권장: 22~27분 · 실험 수치의 분모와 조건을 함께 설명



31번의 주 비교는 얼굴 이미지 전체 입력 YOLO26n, YOLO26s, MobileNetV3-Small 세 모델입니다. 같은 393장, 같은 RGB 224 패딩, 같은 임계값 0.50에서 비교했습니다. 정확도는 76.34%, 78.37%, 62.34%이고 재현율은 56.14%, 75.44%, 29.82%였습니다. YOLO26s가 이 조건의 정확도와 재현율에서 가장 높았습니다. 이번 정리에서는 저장된 이미지별 예측을 다시 집계하고 현재 가중치로 재추론해 TP·TN·FP·FN이 모두 일치하는지 확인했습니다. 31번 파일에 함께 있는 팀 ResNet 결과는 이전 CSV를 가져온 참고값이며 이 세 모델에 포함하지 않았습니다. YOLO26s의 임계값 0.50에서는 308장 정답, 실제 하품 탐지 129장, 비하품 오탐 43장, 하품 놓침 42장이었습니다. 0.15로 낮추면 하품 재현율은 98.25%로 높아지지만 오탐이 106장으로 늘고 정확도는 72.26%로 낮아집니다. F1은 75.51%로 0.50의 75.22%보다 조금 높으므로 모든 지표의 최고점이라고 주장하지 않았습니다. 데모는 기본 임계값 0.50에서 정확도와 재현율의 균형을 선택했습니다. 입력은 31번 face 모드와 같은 원본 이미지 전체입니다. 새로운 얼굴 박스를 검출하거나 입만 잘라 넣은 결과가 아닙니다. 최종 하품 후보의 예측을 네 칸으로 나누면 실제 비하품 222장 중 179장은 정상, 43장은 하품으로 오탐했습니다. 실제 하품 171장 중 129장을 감지했고 42장은 놓쳤습니다. 정확도는 정답 308장을 전체 393장으로 나눈 78.37%입니다. 하품 재현율은 129 나누기 171로 75.44%, 정밀도는 하품 경고 172건 중 129건이 맞은 75%입니다. F1은 75.22%입니다. 얼굴 전체 분류 경로는 외부 평가에서 입 ROI 실패로 이미지를 제외하지 않았습니다. 그러나 라이브의 얼굴 확인과 지속 시간 조건까지 이 표로 검증한 것은 아닙니다.

근거: 실험별 상세 근거: 근거자료.md 및 기존 37장 slide_manifest.json

AURA DRIVE / 실험과 검증

하품 최종 기준은 재현율과 오탐을 함께 고려했습니다

YOLO26s · 전체 이미지 · 같은 393장에 대한 임계값 비교

Yawn 기준	정확도	재현율	오탐 / 미검출
0.50 · 선택	78.37%	75.44%	43 / 42
0.15	72.26%	98.25%	106 / 3
0.10	68.70%	99.42%	122 / 1



최종 후보에도 오류가 남습니다.

기준을 너무 낮추면 하품을 많이 잡지만 비하품 경고도 증가합니다.
사진의 정답은 평가 데이터 라벨 기준입니다.

final_model_selection/selected_models.json · 선정근거.md · reports/yawn_external_model_compare/predictions.csv · yolo26s / face / 0.50

2026.11.09 · 연구 시연 프로토타입

14 / 20

YOLO26s의 임계값 0.50에서는 308장 정답, 실제 하품 탐지 129장, 비하품 오탐 43장, 하품 놓침 42장이었습니다. 0.15로 낮추면 하품 재현율은 98.25%로 높아지지만 오탐이 106장으로 늘고 정확도는 72.26%로 낮아집니다. F1은 75.51%로 0.50의 75.22%보다 조금 높으므로 모든 지표의 최고점이라고 주장하지 않았습니다. 데모는 기본 임계값 0.50에서 정확도와 재현율의 균형을 선택했습니다. 입력은 31번 face 모드와 같은 원본 이미지 전체입니다. 새로운 얼굴 박스를 검출하거나 입만 잘라 넣은 결과가 아닙니다. 이번 사진은 이전 ResNet의 입 ROI 오류가 아니라 최종 선정한 YOLO26s 전체 이미지 경로의 오류입니다. 왼쪽 두 장은 데이터셋 정답이 비하품인데 하품으로 판단한 오탐이고, 오른쪽 두 장은 실제 하품 라벨인데 놓친 미탐입니다. 얼굴 자세와 입 모양, 가림, 조명과 촬영 맥락을 확인할 수 있습니다. 모델이 특정 주름이나 색 때문에 틀렸다고 단정하지는 않습니다. 이 사례는 앞으로 추가할 어려운 양성·음성 데이터와 영상 이벤트 정답을 구체화하는 데 사용합니다. 후보를 선정했다고 남은 오류까지 해결된 것은 아닙니다.

근거: final_model_selection/selected_models.json · 선정근거.md · reports/yawn_external_model_compare/predictions.csv · yolo26s / face / 0.50

발표 권장: 22~27분 · 실험 수치의 분모와 조건을 함께 설명



최종 경로는 이전 입 ROI ResNet 경로와 다릅니다. 눈은 원본에서 MediaPipe 눈 ROI를 추출하고 CLAHE와 패딩을 거쳐 YOLO26n에 넣습니다. 하품은 원본 이미지 전체를 RGB 224 곱하기 224로 패딩해 YOLO26s에 넣습니다. 31번 face 모드는 별도의 얼굴 검출 크롭이 아니라 원본 전체 입력입니다. 앱도 같은 분류 전처리를 재사용하도록 수정했습니다. 라이브에서는 얼굴이 보이는지 확인한 뒤 점수와 지속 시간으로 경고하며, 얼굴 미검출이나 오래된 결과는 판단을 보류합니다. 이 얼굴 확인과 지속 시간을 포함한 통합 성능은 외부 정지 이미지 정확도와 별도로 평가해야 합니다. 선정 결과를 앱에 반영해 눈은 기존 YOLO26n과 CLAHE, 하품은 전체 이미지 YOLO26s를 기본으로 연결했습니다. 눈 임계값은 0.25, 하품은 0.50입니다. 입 ROI ResNet은 이전 비교 경로로 남기고 기존 가중치와 실험 자료는 보존했습니다. 눈 CEW 정확도는 88.36%, 하품 Roboflow 정확도는 78.37%입니다. 두 값은 서로 다른 정지 이미지 평가셋에서 얻은 값이며 평균내서 시스템 정확도라고 할 수 없습니다. 외부 자료는 후보 선택에도 쓰였으므로 최종 개발 후보이며, 새로운 인물의 영상에서 이벤트 재현율과 오경고를 검증해야 합니다.

근거: 11_streamlit_dashboard.py · roi_utils.py · 31_yawn_external_compare.py · reports/final_model_selection/selected_models.json · 11_streamlit_dashboard.py

발표 권장: 22~27분 · 실험 수치의 분모와 조건을 함께 설명



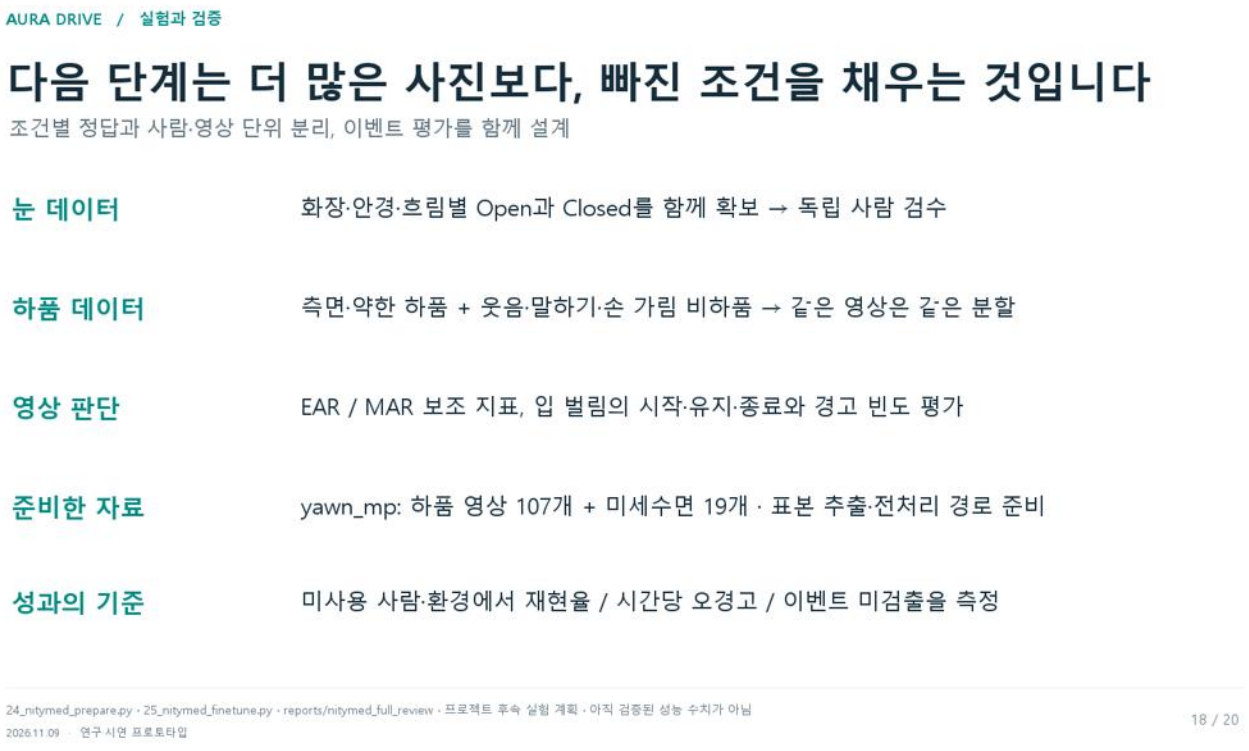
현재 웹캠 화면은 로컬 JPEG 스트림으로 전송하고, AI 작업은 별도 스레드에서 최신 대기 프레임을 처리합니다. 카메라 표시가 모델 추론 완료를 기다리는 구조를 피하려는 목적입니다. 기본 분석 간격은 350ms이고 화면 전송 상한은 20FPS로 설정돼 있습니다. 이 수치는 설정값이며 실제 카메라 FPS나 처리 지연을 보장하지 않습니다. 현재 앱의 모델·임계값과 사진 입력 확률이 31번 기록에 맞는지 따로 확인했습니다. 이전 앱 버전의 단기 웹캠 측정치를 현재 버전 성능으로 인용하지 않았습니다. 나이와 지병을 입력받아 기절이나 발작을 판단하는 확장도 생각했지만, 현재 눈·입 분류 모델에는 의학적 정답과 검증 근거가 없습니다. 사람마다 나타나는 양상이 다르고 단순 무반응이나 눈 감김을 응급 질환으로 단정하면 잘못된 경보와 신고로 이어질 수 있습니다. 그래서 화면 속 가상 감속, 정차, 응답 확인, 모의 SOS까지만 구현했습니다. 실제 차량 제어와 실제 119 신고는 하지 않습니다. 입력 정보만으로 의식 상실을 측정하는 기능이 있다고 발표하지 않으며, 시간 기준도 시연용으로 설명합니다.

근거: aura_local_camera.py · 11_streamlit_dashboard.py · test_aura_local_camera.py · aura_safety_sim.py · Streamlit 시연



첫 번째 한계는 선글라스입니다. 눈이 가려지면 눈 감김을 관찰하기 어렵고, 착용 여부만 표시된 데이터로는 가려진 눈의 정답을 학습할 수 없습니다. 임계값을 늦춰도 사라진 눈 정보가 복원되지 않습니다. 두 번째는 야간입니다. 일반 RGB 웹캠은 부족한 빛의 영향을 받으므로 별도 야간 데이터와 센서 검증이 필요합니다. 세 번째는 발작 등 응급 상태의 판단입니다. 발작은 사람과 유형에 따라 나타나는 양상이 다양합니다. 현재 프로젝트에는 이러한 범위를 포괄하는 정답 데이터나 임상 검증이 없고 실제 측정 대상도 눈 감김과 하품입니다. 따라서 발작을 감지하거나 진단한다고 주장할 수 없습니다. 잘못된 판단과 허위 신고 가능성을 고려해 응급 대응은 가상 감속, 응답 확인, 모의 SOS 시뮬레이션까지만 보여줍니다.

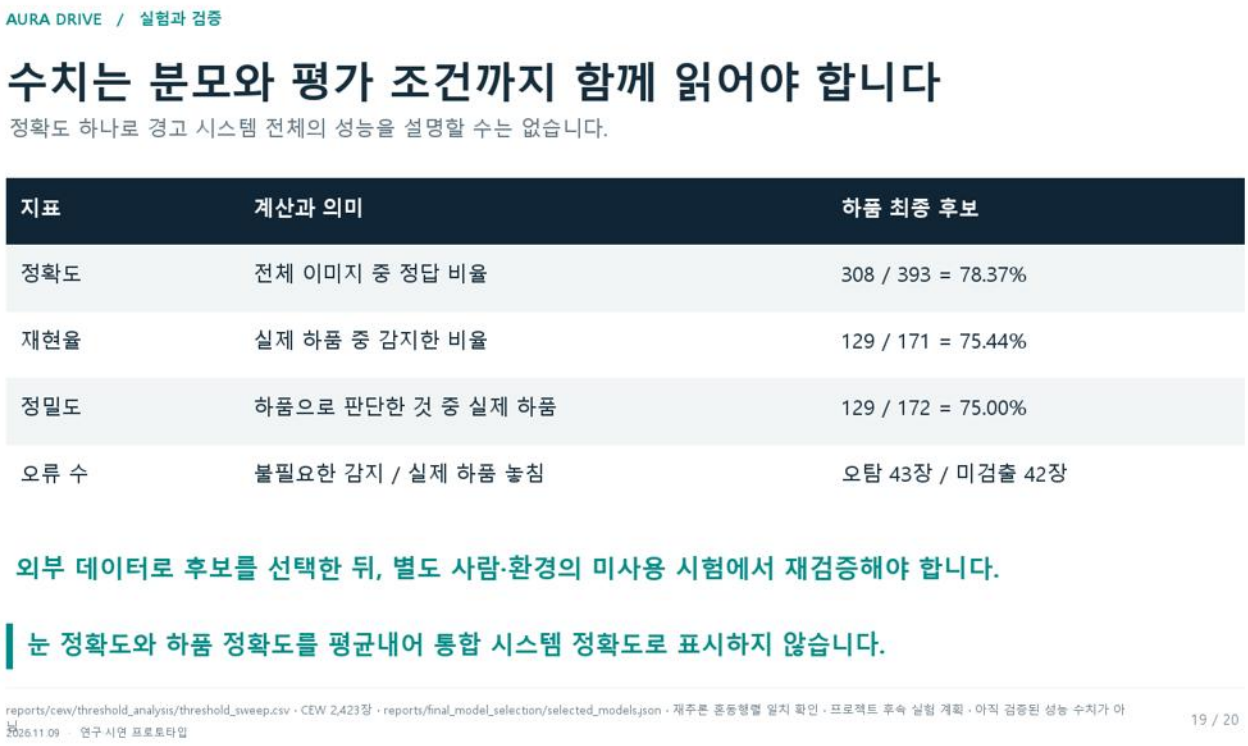
근거: 프로젝트 구현 범위 · NHS Epilepsy · https://www.nhs.uk/conditions/epilepsy/ · Tesla / NIR: 근거자료.md



현재 폴더에는 Yawning 107개와 Microsleep 19개, 총 126개 영상이 있습니다. 모두를 하품 영상으로 세지 않았습니다. 24번 코드는 프레임을 추출해 기존 팀 모델과 같은 방식으로 입 ROI를 만듭니다. 25번 코드는 확인된 하품·비하품 라벨만 읽고 그룹을 나눈 뒤 추가 학습하는 경로입니다. 현재 폴더에서 25번의 학습 완료 comparison.json과 최종 가중치는 확인되지 않아 정확도 향상 수치로 넣지 않았습니다. 영상 폴더 이름이나 모델 예측을 프레임의 정답으로 쓰면 안 됩니다. 인물 ID와 이벤트 정답을 검수한 뒤 학습하고 새 사람으로 평가하는 것이 다음 단계입니다. 발표에는 영상 파일을 넣지 않았습니다. 눈은 화장한 Open뿐 아니라 Closed, 안경과 가림 조건까지 균형 있게 확보해야 합니다. 하품은 약한 하품과 측면 하품, 말하기·웃기 같은 비하품을 함께 모아야 합니다. 같은 사람의 사진과 영상은 하나의 분할에 묶고 새로운 평가 자료는 모델과 임계값을 선택하기 전에 분리합니다. 이후 EAR·MAR 같은 랜드마크 지표와 입이 열리고 닫히는 지속 시간을 보조 정보로 비교할 수 있습니다. 마지막으로 정확도뿐 아니라 하품 이벤트 재현율, 시간당 오경고와 경고 지연을 측정하겠습니다. 이러한 후속 기능은 구현된 성과와 구분합니다.

근거: 24_nitymed_prepare.py · 25_nitymed_finetune.py · reports/nitymed_full_review · 프로젝트 후속 실험 계획 · 아직 검증된 성능 수치가 아님

발표 권장: 22~27분 · 실험 수치의 분모와 조건을 함께 설명



정확도는 전체 중 맞힌 비율이고 재현율은 실제 양성 중 감지한 비율입니다. 최종 하품 후보는 393장 중 308장을 맞혔지만 하품 171장 중 42장은 놓쳤습니다. 눈에서는 ROI 추출 실패를 포함한 전체 평가와 추출에 성공한 사진만의 조건부 평가를 구분했습니다. 또한 CEW와 Roboflow는 설정과 모델 선택에도 사용했기 때문에 미사용 최종 시험은 아닙니다. 서로 다른 두 데이터의 점수를 평균내 통합 시스템 정확도로 발표하지 않습니다. 다음 검증에서는 사람과 영상을 분리하고 시간당 오경고와 실제 이벤트 미검출을 함께 측정하겠습니다.

근거: reports/cew/threshold_analysis/threshold_sweep.csv · CEW 2,423장 · reports/final_model_selection/selected_models.json · 재추론 혼동행렬 일치 확인 · 프로젝트 후속 실험 계획 · 아직 검증된 성능 수치가 아님

발표 권장: 22~27분 · 실험 수치의 분모와 조건을 함께 설명



이번 프로젝트의 핵심은 내부에서 100%가 나온 모델을 그대로 신뢰하지 않고 외부 데이터와 직접 촬영 이미지로 확인한 것입니다. 눈은 입력 영역을 맞추고 CLAHE 및 확률 기준을 조정해 CEW에서 정확도 88.36%, Closed 재현율 90.69%를 얻었습니다. 하품은 동일 외부 이미지로 세 모델을 비교해 YOLO26s 전체 이미지 입력을 최종 개발 후보로 선택했고 정확도 78.37%, 재현율 75.44%였습니다. 이는 서로 다른 데이터의 개별 분류 결과이며 통합 정확도가 아닙니다. 앞으로 실제 이벤트와 새로운 사람에 대한 검증을 통해 불필요한 경고와 미검출을 줄이는 것이 목표입니다.

근거: 검증 CSV / 그래프 원본 / PPT / 발표대본 제공