AURA DRIVE | 발표대본 01/33



저희는 눈 감김과 하품이라는 두 가지 시각적 행동을 분류하고, 지속 시간에 따라 경고하는 데모를 만들었습니다. 프로젝트의 핵심은 높은 내부 정확도를 그대로 믿지 않고, 실제 촬영 사진과 외부 데이터로 검증했다는 점입니다. 데이터 수집과 전처리, 세 가지 모델의 선택 이유, 오류 분석과 개선 과정을 눈 모델부터 설명하겠습니다. 마지막에는 Streamlit 구현 범위와 야간·선글라스·응급 대응의 한계를 말씀드리겠습니다.

근거: 로컬 학습·평가 기록 검증 · 2026.11.08

발표 권장: 18~22분 · 실험 수치의 분모와 조건을 함께 설명



눈은 Open과 Closed, 입은 no_yawn과 yawn으로 나눴습니다. 두 부위는 동시에 다른 상태일 수 있으므로 네 클래스를 하나의 모델로 묶기보다 각각 분류하도록 구성했습니다. 눈 감김과 하품은 카메라로 관찰할 수 있고 화면·소리 경고로 연결하기 쉬워 선택했습니다. 다만 눈을 감았다고 모두 졸음인 것은 아니며, 하품만으로 의식 상태나 질병을 진단할 수도 없습니다. 여기서 구현한 것은 행동 분류와 경고 시나리오입니다.

근거: common.py · 03_yawn_common.py · 클래스 폴더

AURA DRIVE / 실험과 검증

출발점은 네 종류의 이미지 2,900장이었습니다

원본 폴더 라벨을 확인하고 작업별로 다시 분할

클래스	원본 수	작업
Closed	726	눈
Open	726	눈
no_yawn	725	하품
yawn	723	하품

학습 자료 · 직접 촬영 검증 · 외부 평가 자료를 분리해 관리했습니다.

data/raw · data/processed/manifest.csv · 01_audit_data.py

2026.11.08 · 연구 시연 프로토타입

03 / 33

로컬 원본에는 Closed 726장, Open 726장, 비하품 725장, 하품 723장이 있습니다. 학습 전에 파일을 열 수 있는지, 라벨과 폴더가 맞는지, 중복은 없는지 확인했습니다. 기존 train과 test 폴더 이름을 그대로 신뢰하지 않고 정제 후 다시 나눴습니다. 공개 수집 이미지와 직접 촬영 사진, 이후 외부 평가 자료는 역할을 구분했습니다. 원본 다운로드 페이지와 이용 조건이 완전히 보존되지 않은 자료는 출처 추적의 한계로 남겼으며 임의의 출처 주소를 붙이지 않았습니다.

근거: data/raw · data/processed/manifest.csv · 01_audit_data.py



완전 중복은 해시로 제거하고, 동일 이미지에 상충하는 라벨이 있으면 제외하도록 했습니다. 유사 이미지는 dHash 해밍 거리 5 이하를 기준으로 그룹화해 같은 그룹이 분할을 넘지 않게 했습니다. 이후 약 70 대 15 대 15로 학습·검증·테스트를 나누고 종횡비를 유지한 224 곱하기 224 패딩을 적용했습니다. 눈은 1017·218·217장, 하품은 1016·218·214장입니다. 이는 유사 이미지 단위 분리이지, 모든 사람의 신원이 완전히 분리됐음을 보장하는 것은 아닙니다.

근거: 02_prepare.py · common.py · data/processed/manifest.csv

발표 권장: 18~22분 · 실험 수치의 분모와 조건을 함께 설명

AURA DRIVE / 실험과 검증

눈 모델은 속도와 구조가 다른 세 가지로 비교했습니다

사전학습된 분류 모델을 두 클래스에 맞춰 전이학습

모델	선택 이유	입력과 출력
YOLO26n-cls	경량 분류 · CPU 데모 후보	224×224 → Open / Closed
ResNet18	잔차 CNN · 비교 기준	동일 클래스·분할
MobileNetV3-Small	작은 모델 · 연산량 비교	동일 클래스·분할

ROI 검출은 MediaPipe, 상태 분류는 YOLO/CNN이 담당합니다.

03_train.py · 08_train_cnn.py · 저장된 체크포인트
2026.11.08 · 연구 시연 프로토타입

05 / 33

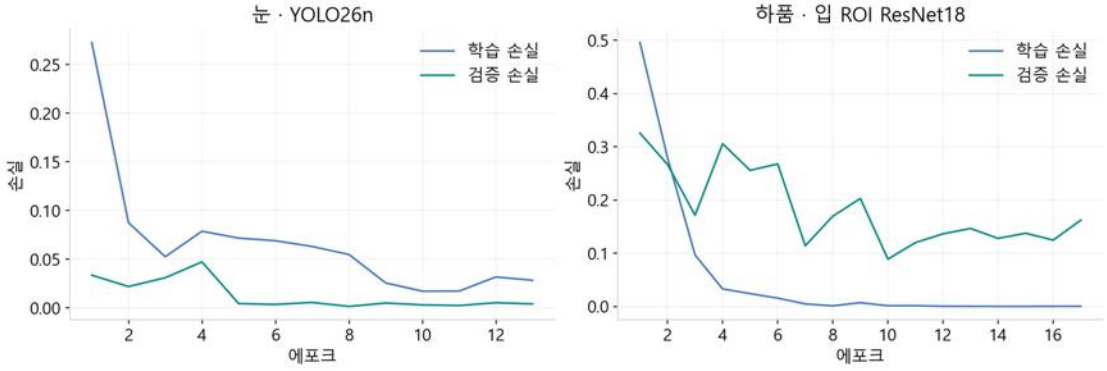
YOLO26n-cls는 작은 분류 모델로 로컬 CPU에서도 사용할 수 있는 경량 후보였습니다. ResNet18은 잔차 연결을 쓰는 대표적인 CNN으로 비교 기준을 만들기 좋았습니다. MobileNetV3-Small은 경량 연산을 목표로 한 구조여서 크기와 지연을 비교하기 위해 선택했습니다. 여기서 YOLO는 물체 검출 박스를 학습하는 모델이 아니라 분류 버전입니다. 얼굴과 눈의 위치는 MediaPipe가 찾습니다. 사전학습 가중치를 활용한 전이학습이며 별도의 상용 클라우드 판별 API를 호출한 것은 아닙니다.

근거: 03_train.py · 08_train_cnn.py · 저장된 체크포인트

AURA DRIVE / 실험과 검증

학습 손실과 검증 손실을 함께 확인했습니다

사전학습 가중치 활용 · 학습용 증강 · 검증 기반 모델 저장



학습 곡선이 좋아도 새로운 촬영 조건에서의 성능은 별도로 확인해야 합니다.

runs/eyes_yolo26n-cls/results.csv · teammate_yawn/runs/03_yawn_resnet18/03_results.csv

2026.11.08 · 연구 시연 프로토타입

06 / 33

그래프는 실제 저장된 에포크별 손실입니다. 눈 YOLO 학습 설정은 최대 25에포크, 배치 16, seed 42, 조기 종료 patience 7입니다. 눈 CNN은 학습 이미지에 좌우 반전과 작은 회전을 적용하고 ImageNet 정규화를 사용했습니다. 하품 ResNet은 입 ROI에 좌우 반전과 약한 색 증강을 사용합니다. 손실이 내려갔다는 사실은 학습이 진행됐다는 근거지만, 새 얼굴과 조명에서 잘 동작한다는 증거까지 되지는 않습니다. 그래서 테스트 다음에 실제 입력과 외부 검증을 추가했습니다.

근거: runs/eyes_yolo26n-cls/results.csv · teammate_yawn/runs/03_yawn_resnet18/03_results.csv



같은 내부 테스트 217장으로 세 모델을 다시 확인했습니다. Closed 102장과 Open 115장을 모두 맞혀 정확도와 Closed 재현율이 각각 100%였습니다. 이 결과만으로 과적합이라고 단정할 수는 없습니다. 데이터가 쉬웠거나 유사한 촬영 환경이 반복됐거나 학습과 평가의 분포가 비슷했을 가능성도 있습니다. 모델 간 차이가 드러나지 않았으므로 파일 크기와 처리 시간을 함께 보고, 외부 얼굴에서도 같은 결과가 나오는지 확인했습니다. 표의 지연은 단일 분류 처리이며 전체 웹캠 지연이 아닙니다.

근거: eyes_baseline_verified.json · 09_compare_models_retry.test_model · CPU 4 threads

AURA DRIVE / 실험과 검증

직접 찍은 얼굴에서는 입력 부위부터 맞춰야 했습니다

같은 65장 · 얼굴 전체 → MediaPipe 눈 ROI





53.85% → 84.62%

얼굴 전체 35/65 → 눈 ROI 55/65

ROI 성공분 91.67%

55/60 · 추출 실패 5장 제외

> **이 결과는 과거 ROI 적용 실험이며, 추가 학습 전후 실험과 구분합니다.**

reports/eyes_yolo26n-cls_extra_confusion.csv · reports/eyes_roi_predictions.csv
2026.11.08 · 연구 시연 프로토타입
08 / 33

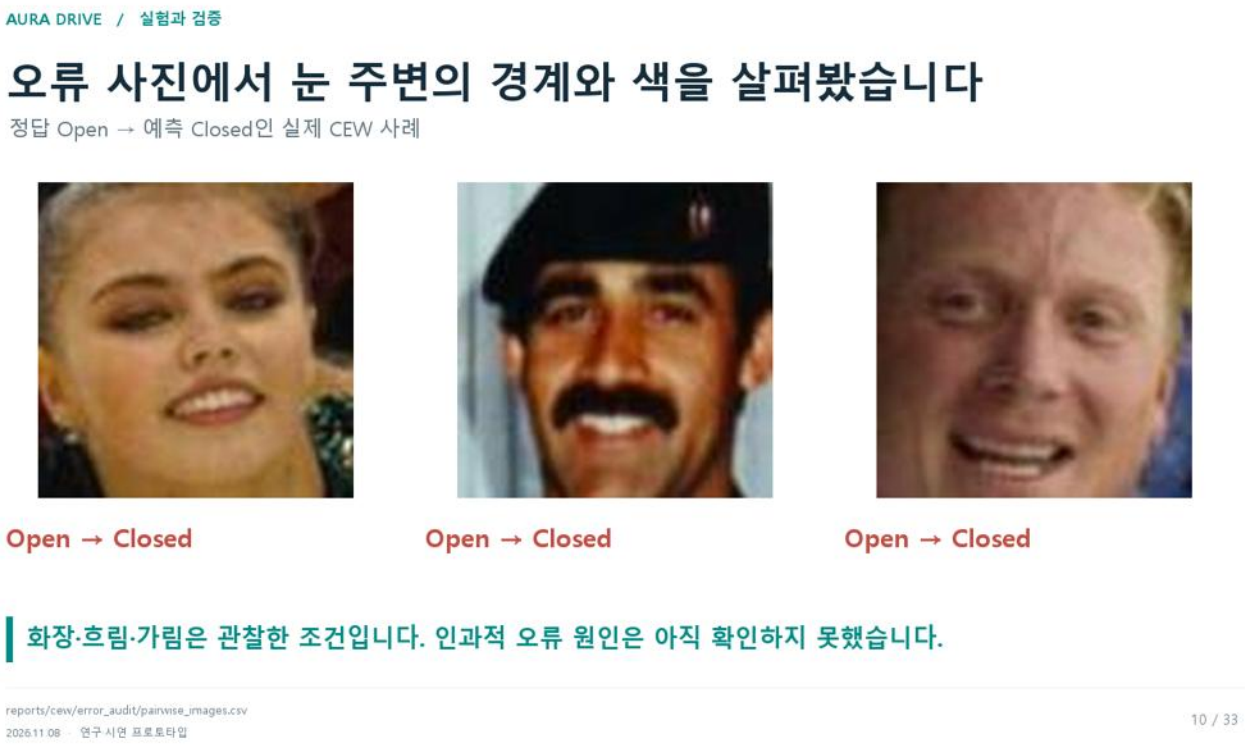
눈 패치로 학습한 모델에 얼굴 전체를 넣었더니 65장 중 35장만 맞혀 53.85%였습니다. MediaPipe로 눈 영역을 잘라 넣은 뒤에는 전체 65장 중 55장을 맞혀 84.62%로 올랐습니다. 눈 ROI가 추출된 60장만 보면 55장 정답으로 91.67%입니다. 추출 실패 5장을 제외한 조건부 수치이므로 84.62%와 섞어서 말하지 않습니다. 이 실험은 모델을 새로 학습하기 전에 학습 입력과 실제 입력의 부위와 크기를 맞추는 것이 중요하다는 근거였습니다.

근거: reports/eyes_yolo26n-cls_extra_confusion.csv · reports/eyes_roi_predictions.csv



외부 눈 평가는 CEW 2423장, MRL 4000장, Simuletic 143장으로 나눠 수행했습니다. MRL은 이미 잘린 눈 패치이며 학습 원자료와 중복 가능성이 있어 강한 독립 검증으로 해석하지 않았습니다. CEW는 얼굴에서 눈을 추출하는 조건으로, 내부 테스트보다 현실적인 입력 차이를 보여줬습니다. 기본 전처리에서 YOLO 정확도는 79.12%, ResNet은 81.18%, MobileNet은 81.55%였습니다. YOLO의 Closed 재현율은 높았지만 Open을 Closed로 보는 오탐이 많아 후속 전처리 실험을 진행했습니다.

근거: reports/{cew,mrl,simuletic}/external_summary.csv



이 사진들은 CEW 오류 감사 기록에 남아 있는 실제 오탐입니다. 정답은 Open인데 기존 YOLO가 Closed로 분류했습니다. 눈 화장, 짙은 눈 주변 색, 낮은 해상도와 흐릿한 경계가 오분류와 함께 관찰됐습니다. 다만 사진만 보고 아이라인이나 주름이 직접 원인이라고 단정할 수는 없습니다. 이러한 관찰을 전처리와 조건별 데이터 보강을 시도하는 가설로 사용했습니다. 오류를 설명하려면 전체 얼굴뿐 아니라 실제 모델에 들어간 눈 ROI도 확인해야 합니다.

근거: reports/cew/error_audit/pairwise_images.csv



왼쪽과 오른쪽은 같은 눈 ROI의 전처리 전후입니다. RGB 이미지를 LAB 색 공간으로 바꾼 뒤 밝기인 L채널에 CLAHE를 적용하고 다시 RGB로 되돌렸습니다. 극단적인 대비 증폭을 제한하면서 국소 경계를 강조하려는 목적입니다. 이후 224 곱하기 224로 패딩해 기존 분류기에 넣었습니다.
이 단계에서는 모델 가중치를 바꾸지 않았습니다. 전체 CEW 지표가 좋아졌다는 사실과 특정 화장 유형의 오류가 해결됐다는 주장은 서로 다른 내용입니다.

근거: 15_roi_ablation.py · LAB L채널 · clipLimit 2.0 · tileGridSize 4×4

AURA DRIVE / 실험과 검증

정확도만 높이기보다 눈 감김을 놓치지 않도록 조정했습니다

CLAHE 이후 Closed 임계값 0.50 → 0.25

전처리 / 임계값	정확도	Closed 재현율	Open 오탐률
RGB / 0.50	79.12%	94.21%	35.09%
CLAHE / 0.50	88.90%	81.12%	3.17%
CLAHE / 0.25	88.36%	90.69%	13.48%

> 임계값은 분류 기준입니다. 지속 시간 2초와도 서로 다른 설정입니다.

reports/cew/threshold_analysis/threshold_sweep.csv · CEW 2,423장
2026.11.08 · 연구 시연 프로토타입

12 / 33

기존 RGB의 정확도는 79.12%이고 Closed 재현율은 94.21%였지만 Open 오탐률이 35.09%로 높았습니다. CLAHE만 적용하면 정확도는 88.90%로 높아지지만 Closed 재현율이 81.12%로 떨어졌습니다. 그래서 눈 감김을 더 잡는 방향으로 확률 기준을 0.25로 낮췄습니다. 정확도는 88.36%, Closed 재현율은 90.69%, Open 오탐률은 13.48%였습니다. 가중치 재학습이 아니라 판정 민감도 조정입니다. CEW를 설정 선택에도 썼으므로 이 결과는 독립 최종 시험 성능이 아닙니다.

근거: reports/cew/threshold_analysis/threshold_sweep.csv · CEW 2,423장

AURA DRIVE / 실험과 검증

화장 조건을 확인하기 위해 별도 이미지를 모았습니다

화장 전·후 폴더명은 조건이며, 눈 정답 라벨과 다릅니다.



화장 전 · 같은 번호의 사진



화장 후 · 같은 번호의 사진

data/error_data · reports/hardcase_finetune/annotations.csv

2026.11.08 · 연구 시연 프로토타입

13 / 33

추가 폴더에는 화장 전 26장, 화장 후 26장, 주름 조건 459장이 있었습니다. 이 폴더명을 곧바로 Open이나 하품 라벨로 쓰지 않고 이미지별로 눈과 입을 확인했습니다. 눈은 보이는 Open 51장만 라벨이 확정됐고 불확실한 사진은 제외했습니다. 화장 전후 같은 사람의 사진은 같은 분할에 넣었습니다. 이 판독은 AI 보조 육안 검토이며 독립적인 사람 검수까지 완료된 정답은 아닙니다. Closed 사례가 없어 화장한 눈의 감김까지 해결했는지 평가하기에는 부족합니다.

근거: data/error_data · reports/hardcase_finetune/annotations.csv



전처리 실험 다음에는 실제 가중치를 바꾸는 별도 실험도 수행했습니다. 특징을 추출하는 본체는 고정하고 마지막 분류층만 학습했습니다. 기존 일반 데이터 손실 80%, 새 데이터 손실 20%를 사용했고 학습률은 0.0001, 최대 40회 업데이트였습니다. 검증 손실로 후보를 선택한 뒤 동일한 CEW와 임계값 0.25로 비교했습니다. 정확도는 88.36%에서 88.90%, Closed 재현율은 90.69%에서 91.11%로 변했습니다. 소폭 변화이며 특정 화장 조건의 해결이나 실차 성능으로 일반화하지 않았습니다.

근거: reports/hardcase_finetune/eyes_config.json · eyes_summary.csv

AURA DRIVE / 실험과 검증

눈 모델의 개선 범위는 평가셋마다 달랐습니다

추가 학습 후보와 기존 모델을 같은 조건에서 재검증

동일 조건 비교	기존 가중치	추가 학습 후보
CEW · 2,423장	88.36%	88.90%
Simuletic · 143장	97.90%	97.20%
직접 촬영 · 65장	89.23%	89.23%

> 추가 학습 후보는 앱에 자동으로 교체하지 않았습니다.

reports/hardcase_finetune/eyes_summary.csv · threshold 0.25

2026.11.08 · 연구 시연 프로토타입

15 / 33

CEW에서는 정답이 13장 늘었지만, Simuletic은 140장 정답에서 139장으로 바뀌었습니다. 직접 촬영 사진은 이번 전처리 조건에서 58장 정답으로 변화가 없었습니다. 직접 촬영의 이번 89.23%는 앞에서 본 과거 ROI 실험 84.62%와 입력 크기·CLAHE·임계값 조건이 달라 구분해야 합니다. 새 화장 조건 테스트는 Open 12장 모두 기존부터 맞혔으므로 개선 근거가 되지 않습니다. 따라서 앱은 검증해 사용하던 기존 눈 가중치를 유지하고 추가 학습 파일은 별도 후보로 보관합니다.

근거: reports/hardcase_finetune/eyes_summary.csv · threshold 0.25



눈 모델은 내부 100%라는 숫자에서 출발했지만, 얼굴 전체 입력과 외부 얼굴에서는 다른 결과가 나왔습니다. 첫 번째 해결은 모델 교체가 아니라 눈 ROI를 사용해 입력을 맞추는 일이었습니다. 두 번째는 밝기 대비와 판정 민감도를 조정하는 일이었습니다. 세 번째 추가 학습에서는 소폭 변화가 있었지만 모든 조건에서 개선되지는 않았습니다. 이 과정을 통해 데이터 조건과 전처리, 임계값, 모델 가중치를 각각 구분해서 평가해야 한다는 점을 확인했습니다. 다음은 같은 질문을 하품 모델에 적용한 과정입니다.

근거: 눈 실험 종합 · 06 / 15 / 16 / 22 / 23번 코드

발표 권장: 18~22분 · 실험 수치의 분모와 조건을 함께 설명

AURA DRIVE / 실험과 검증

하품은 입 주변 문맥을 남긴 RGB ROI로 분류했습니다

no_yawn / yawn · 입 모양과 주변 문맥을 함께 입력



얼굴 이미지



MediaPipe 입 ROI → RGB 224×224

teammate_yawn/03_yawn_common.py · crop_config

2026.11.08 · 연구 시연 프로토타입

17 / 33

하품도 얼굴 전체에서 먼저 입 ROI를 추출한 뒤 분류합니다. 팀 하품 모델은 입술 랜드마크 주변을 정사각형으로 잘라 입 주변 문맥을 남기도록 학습했습니다. 설정은 얼굴 기준 크기 224, 입 너비 배율 1.8, 높이 배율 1.35, 중심 보정 0.08이고 최종 입력은 224 곱하기 224입니다. RGB와 ImageNet 정규화를 사용하며, 학습 때만 좌우 반전과 약한 색 증강을 적용했습니다. 눈의 CLAHE를 입에 그대로 적용한 것은 아닙니다. 입을 크게 벌렸다는 사실만으로 하품과 말하기가 항상 구분되지는 않습니다.

근거: teammate_yawn/03_yawn_common.py · crop_config

AURA DRIVE / 실험과 검증

입 ROI 모델도 세 가지 CNN으로 비교했습니다

같은 입 ROI 테스트 성공분 212장 · 임계값 0.50

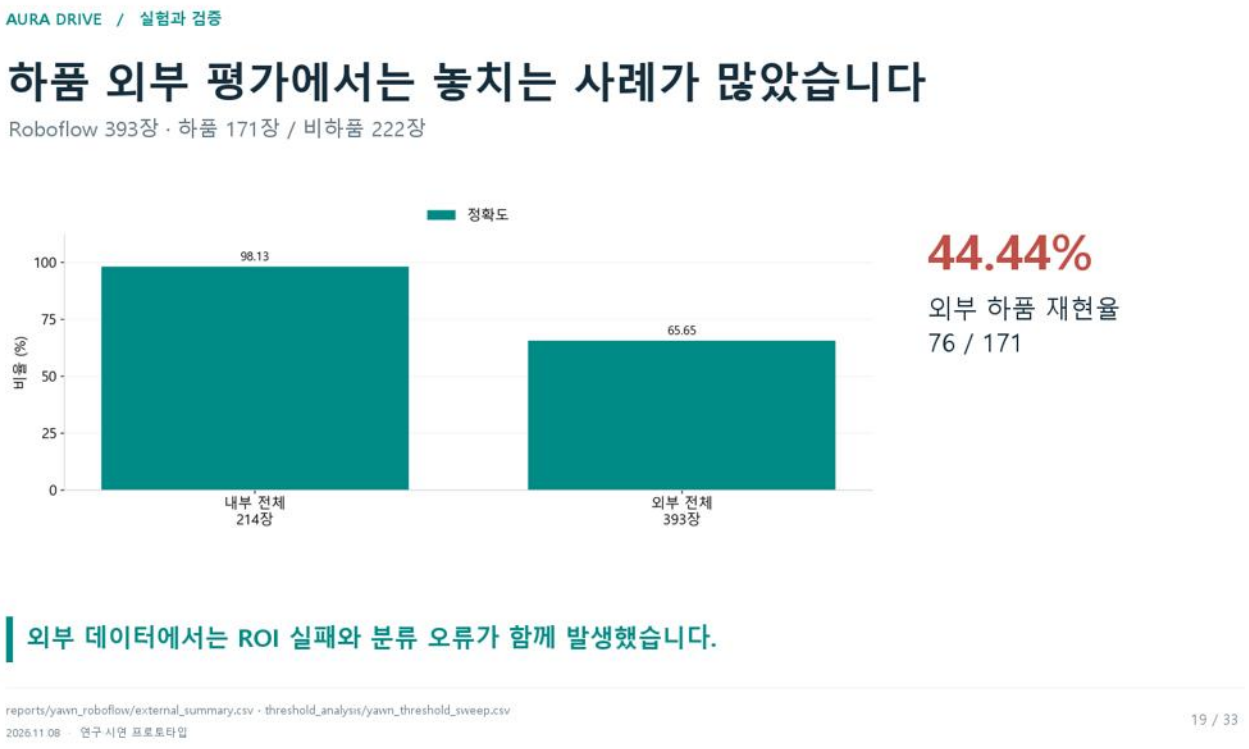
입 ROI 모델	정확도 / 212장	하품 재현율 / 115장
ResNet18	99.06%	98.26%
MobileNetV3-Small	97.64%	96.52%
EfficientNet-B0	97.64%	95.65%

ResNet 전체 입력 기준은 210/214 = 98.13% · ROI 성공분은 210/212 = 99.06%

teammate_yawn/runs/*/evaluation 또는 *_evaluation/*summary.json
2026.11.08 · 연구 시연 프로토타입
18 / 33

팀의 입 ROI 하품 비교 모델은 ResNet18, MobileNetV3-Small, EfficientNet-B0입니다. 눈 비교의 YOLO·ResNet·MobileNet 세 모델과 구성을 구분해야 합니다. ResNet은 기준 CNN, MobileNet은 경량성, EfficientNet은 규모 대비 표현력 비교를 위한 선택입니다. ROI 성공 212장에서는 ResNet 정확도 99.06%, 하품 재현율 98.26%로 가장 높았습니다. 다만 전체 원본은 214장이므로 ROI 실패 2장을 포함하면 ResNet 전체 정답률은 98.13%입니다. 이 내부 결과를 바탕으로 입 ROI ResNet을 데모에 연결했습니다.

근거: teammate_yawn/runs/*/evaluation 또는 *_evaluation/*summary.json



별도 출처의 Roboflow 393장에서는 같은 입 ROI ResNet의 정확도가 65.65%, 하품 재현율이 44.44%였습니다. 하품 171장 중 76장만 잡은 것입니다. 입 ROI 추출 실패는 전체 49장이고, 이 중 실제 하품은 22장입니다. ROI 성공분 344장만 보면 정확도는 75%지만 전체 정확도는 실패를 포함한 65.65%로 보고했습니다. 하품 외부 데이터가 눈보다 적은 이유는 두 모델의 ROI 방식 차이가 아니라 확보한 독립 자료와 프로젝트 범위의 차이입니다. 외부 평가가 늦아 전처리·임계값·다른 모델을 순서대로 비교했습니다.

근거: reports/yawn_roboflow/external_summary.csv · threshold_analysis/yawn_threshold_sweep.csv

발표 권장: 18~22분 · 실험 수치의 분모와 조건을 함께 설명



이 사례들은 실제 하품으로 라벨된 이미지지만 모델 점수가 0.10보다 낮아 놓친 사진입니다. 위에는 얼굴, 아래에는 실제 분류기에 입력한 입 ROI를 배치했습니다. 입 벌림 정도, 색감, 턱과 목 주변 선, 가림과 촬영 각도 등을 관찰 항목으로 잡았습니다. 주름이나 입술 색이 원인이라는 결론은 아직 내릴 수 없습니다. 색 전처리를 바꾼 전체 비교와 별도로 조건별 정답이 있는 데이터가 필요하기 때문입니다. 이 오류 분석을 토대로 입력 방식과 모델 후보를 추가로 비교했습니다.

근거: reports/yawn_roboflow/error_audit/all_cases.csv · ROI cache

AURA DRIVE / 실험과 검증

하품 임계값을 낮추자 재현율이 올라갔습니다

가중치는 동일 · Yawn 점수 0.50 → 0.15 / 0.10

Yawn 임계값	정확도	하품 재현율	오탐	놓침
0.5	65.65%	44.44%	13	95
0.15	71.50%	64.33%	24	61
0.1	71.50%	66.67%	28	57

71.50%를 실제 차량에 충분한 정확도로 주장하지 않습니다.

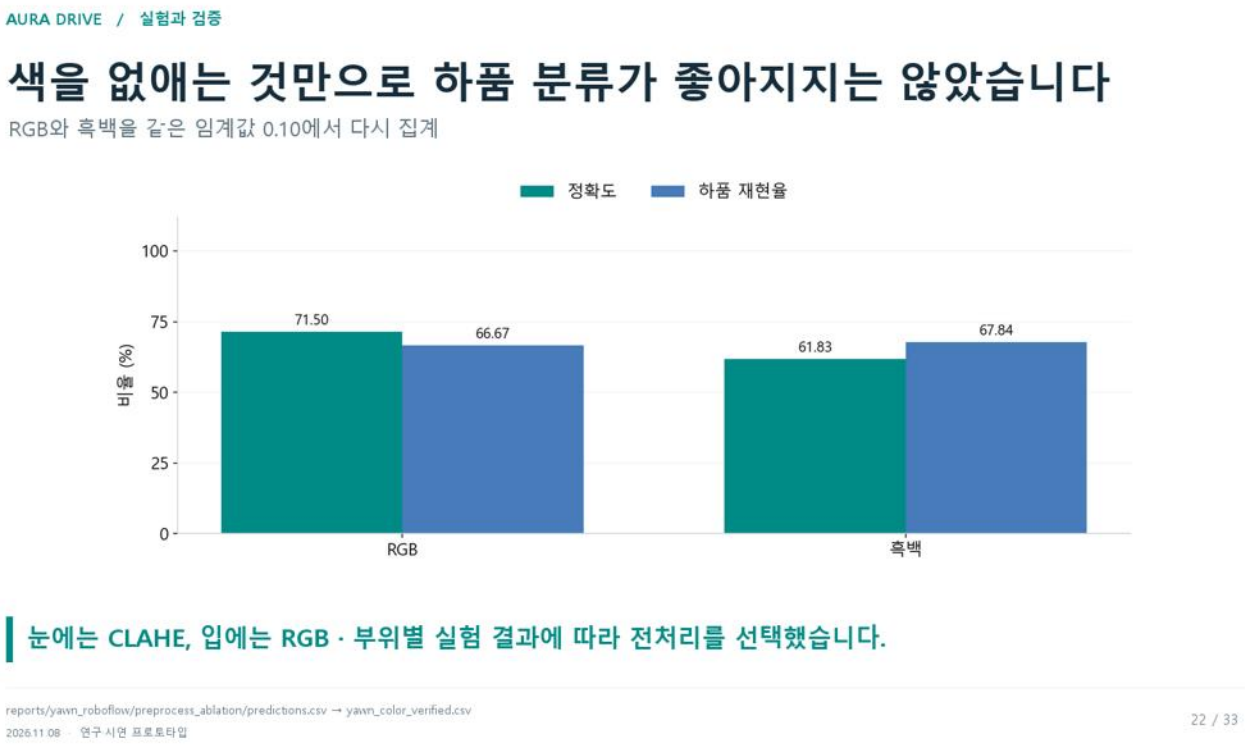
reports/yawn_roboflow/threshold_analysis/yawn_threshold_sweep.csv

2026.11.08 · 연구 시연 프로토타입

21 / 33

임계값 0.50에서는 정확도 65.65%, 하품 재현율 44.44%였습니다. 0.15로 낮추면 정확도 71.50%, 재현율 64.33%이고, 0.10에서는 정확도는 같지만 재현율이 66.67%입니다. 대신 비하품 오탐이 13장에서 24장 또는 28장으로 늘어납니다. 임계값은 놓침과 오탐을 교환하는 설정이며, 낮출수록 무조건 좋아지는 것은 아닙니다. 0.10에서도 하품 171장 중 57장을 놓쳤고, 그중 22장은 ROI 실패입니다. 현재 앱 기본값은 0.15이며 0.10도 비교한 후보입니다.

근거: reports/yawn_roboflow/threshold_analysis/yawn_threshold_sweep.csv



입술 색이나 피부 주름이 영향을 주는지 살펴보기 위해 흑백 입력도 비교했습니다. 같은 ROI와 임계값 0.10에서 RGB 정확도는 71.50%, 재현율은 66.67%이고, 흑백은 정확도 61.83%, 재현율 67.84%였습니다. 흑백의 재현율이 약간 높아도 비하품 오탐이 28장에서 68장으로 늘어 전체 균형이 나빴습니다. 따라서 현재 입 ROI 경로는 RGB를 유지합니다. 이 결과 역시 색이 모든 오류의 원인임을 증명하지 않으며, 특정 입술색 조건을 해결했다고 말할 근거도 아닙니다.

근거: reports/yawn_roboflow/preprocess_ablation/predictions.csv → yawn_color_verified.csv

AURA DRIVE / 실험과 검증

외부 성능이 낮아 기존 하품 모델들을 다시 비교했습니다

같은 Roboflow 393장 · 임계값 0.50 고정

모델	입력	정확도	하품 재현율	비하품 오탐
mobilenet_v3_small	얼굴 전체	62.34%	29.82%	28
yolo26n	얼굴 전체	76.34%	56.14%	18
yolo26s	얼굴 전체	78.37%	75.44%	43
team_resnet18	입 ROI	65.65%	44.44%	13

YOLO26s + 얼굴 전체 78.37%는 별도 후보입니다. 현재 앱의 성능으로 표시하지 않습니다.

31_yawn_external_compare.py · reports/yawn_external_model_compare/summary.csv
2026.11.08 · 연구 시연 프로토타입

23 / 33

외부 성능이 낮아서 이미 학습한 다른 하품 모델도 같은 393장으로 돌렸습니다. 얼굴 전체 입력 MobileNet 정확도는 62.34%, YOLO26n은 76.34%, YOLO26s는 78.37%였습니다. YOLO26s의 하품 재현율은 75.44%입니다. 입 ROI ResNet은 같은 임계값에서 정확도 65.65%, 재현율 44.44%였습니다. 다만 이 비교는 모델 구조뿐 아니라 학습된 입력 방식도 다릅니다. 동일 모델에 추가 학습해 정확도를 올린 결과가 아니라, 다른 모델과 입력 조합을 비교한 결과입니다. YOLO26s를 앱에 교체한 상태는 아닙니다.

근거: 31_yawn_external_compare.py · reports/yawn_external_model_compare/summary.csv

발표 권장: 18~22분 · 실험 수치의 분모와 조건을 함께 설명

AURA DRIVE / 실험과 검증

모델을 바꾸면 학습한 입력 형태도 함께 맞춰야 합니다

얼굴로 학습한 YOLO에 입 ROI를 넣은 대조 실험

동일 가중치	얼굴 전체 입력	입 ROI 입력
yolo26n	76.34%	34.61%
yolo26s	78.37%	37.40%

분류기 선택 = 모델 + 학습 데이터 + 입력 전처리의 조합

reports/yawn_external_model_compare/summary.csv · threshold 0.50

2026.11.08 · 연구 시연 프로토타입

24 / 33

얼굴 전체로 학습한 YOLO가 입 ROI에서도 더 좋을지 확인했습니다. YOLO26n은 얼굴 입력 76.34%에서 입 ROI 입력 34.61%로, YOLO26s는 78.37%에서 37.40%로 바뀌었습니다. 같은 가중치라도 학습과 추론의 입력 분포가 달라지면 결과가 크게 달라질 수 있다는 예입니다. 따라서 현재 입 ROI 파이프라인의 ResNet만 YOLO로 바꾸면 외부 표의 78.37%가 그대로 나오는 것은 아닙니다. 얼굴 전체 후보를 쓰려면 별도 입력 분기를 구현하고 실시간 지연과 오류를 다시 검증해야 합니다.

근거: reports/yawn_external_model_compare/summary.csv · threshold 0.50



현재 폴더에는 Yawning 107개와 Microsleep 19개, 총 126개 영상이 있습니다. 모두를 하품 영상으로 세지 않았습니다. 24번 코드는 프레임을 추출해 기존 팀 모델과 같은 방식으로 입 ROI를 만듭니다. 25번 코드는 확인된 하품·비하품 라벨만 읽고 그룹을 나눈 뒤 추가 학습하는 경로입니다. 현재 폴더에서 25번의 학습 완료 comparison.json과 최종 가중치는 확인되지 않아 정확도 향상 수치로 넣지 않았습니다. 영상 폴더 이름이나 모델 예측을 프레임의 정답으로 쓰면 안 됩니다. 인물 ID와 이벤트 정답을 검수한 뒤 학습하고 새 사람으로 평가하는 것이 다음 단계입니다. 발표에는 영상 파일을 넣지 않았습니다.

근거: 24_nitymed_prepare.py · 25_nitymed_finetune.py · reports/nitymed_full_review

발표 권장: 18~22분 · 실험 수치의 분모와 조건을 함께 설명



현재 구현한 흐름은 원본 웹캠에서 MediaPipe로 눈과 입 ROI를 먼저 추출하고, 눈에는 CLAHE와 패딩, 입에는 RGB 전처리를 적용하는 순서입니다. 다음으로 눈 YOLO와 하품 ResNet이 각각 점수를 출력합니다. 그 뒤 임계값과 지속 시간을 확인해 경고합니다. 눈과 입 모델은 별도로 학습했지만 같은 대시보드 안에서 추론 결과를 함께 표시합니다. 이것은 두 모델을 하나의 새 모델로 통합 학습했다는 뜻이 아닙니다. ROI가 잡히지 않거나 결과가 오래되면 판단 불가로 처리합니다.

근거: 11_streamlit_dashboard.py · roi_utils.py · 03_yawn_common.py

AURA DRIVE / 실험과 검증

실험 후보와 실제 앱에 연결한 모델을 구분했습니다

외부 표에서 가장 높은 수치가 곧 앱의 최종 성능은 아닙니다.

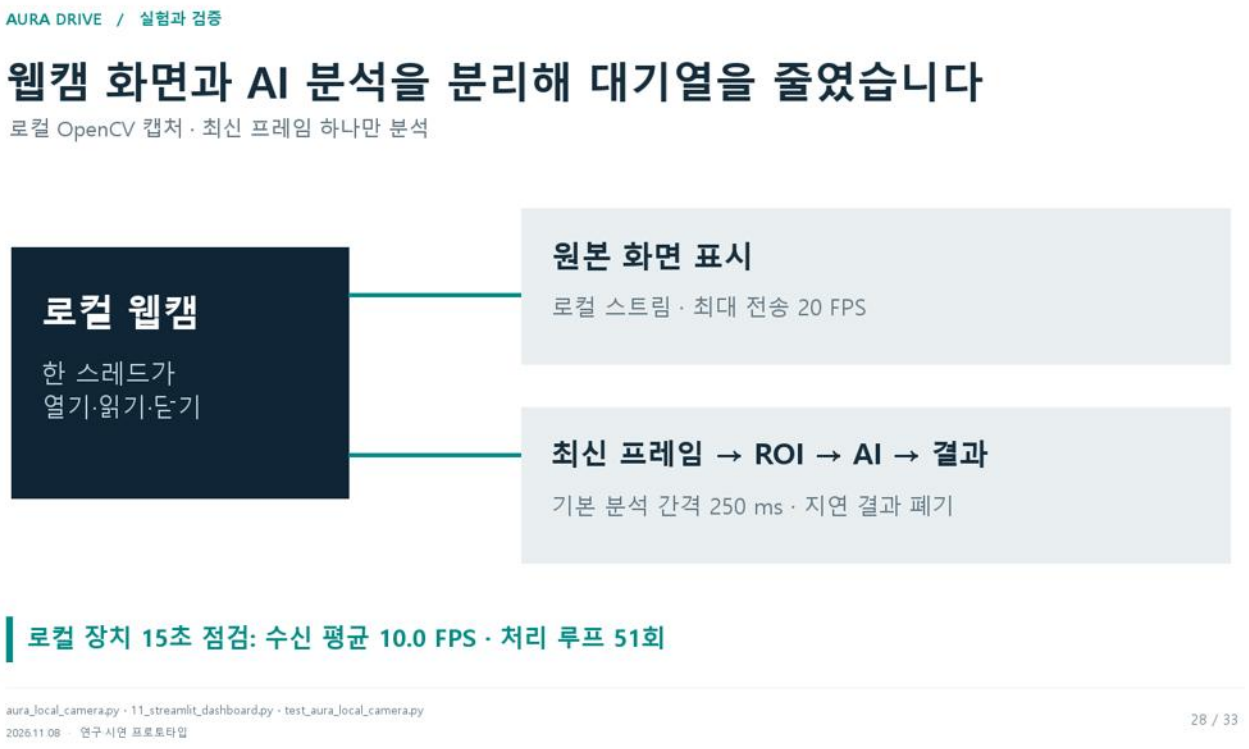
구분	현재 상태	발표에서 의미
눈 YOLO26n + CLAHE	앱 기본 연결	CEW 88.36% / 정지 이미지
하품 입 ROI ResNet18	앱 기본 연결	Roboflow 71.50% / 임계값 0.15
하품 얼굴 YOLO26s	별도 비교 후보	78.37% / 앱에 미적용
통합 영상 이벤트 성능	정량 검증 필요	두 정확도를 평균내면 안 됨

11_streamlit_dashboard.py:model_paths · runs · 31_yawn_external_compare.py
2026.11.08 · 연구 시연 프로토타입

27 / 33

현재 앱은 기존 YOLO26n 눈 모델과 기존 팀 ResNet18 입 모델을 사용합니다. 눈에는 CLAHE와 0.25, 입에는 RGB와 0.15가 기본값입니다. 눈 분류층 추가 학습 파일과 얼굴 입력 YOLO26s 하품 모델은 별도 실험 후보입니다. CEW와 Roboflow 지표는 각각 정지 이미지 평가이고, 두 모델을 동시에 켠 웹캠 시스템의 최종 정확도는 아닙니다. 하나의 시스템 정확도를 말하려면 같은 영상의 눈·하품 정답과 시간 정보로 놓친 이벤트, 오경고와 지연을 함께 평가해야 합니다.

근거: 11_streamlit_dashboard.py:model_paths · runs · 31_yawn_external_compare.py



기존 웹캠 코드에는 카메라를 읽는 동안 다른 스레드에서 해제할 수 있는 구조가 있었습니다. 이를 열기·읽기·해제를 한 캡처 스레드가 담당하도록 바꿨습니다. 화면은 로컬 JPEG 스트림으로 전송하고 AI는 최신 프레임만 가져가므로 오래된 프레임이 줄줄이 쌓이지 않습니다. 오래된 분석 결과는 폐기하며 프레임 수신과 AI 처리 시간을 별도로 표시합니다. 최대 화면 전송 20FPS와 분석 간격 250ms는 설정값이며 실제 장치 성능 보장은 아닙니다. 종료 중 재연결과 늦게 도착한 경고는 회귀 테스트로 확인했습니다. 실제 로컬 카메라 15초 점검에서 연결 후 수신은 약 10 FPS, 처리 루프는 51회였으며 종료도 정상 동작했습니다. 장시간 안정성이나 얼굴 감지 정확도를 측정한 시험은 아닙니다.

근거: aura_local_camera.py · 11_streamlit_dashboard.py · test_aura_local_camera.py · webcam_verification.json

발표 권장: 18~22분 · 실험 수치의 분모와 조건을 함께 설명



나이와 지병을 입력받아 기절이나 발작을 판단하는 확장도 생각했지만, 현재 눈·입 분류 모델에는 의학적 정답과 검증 근거가 없습니다. 사람마다 나타나는 양상이 다르고 단순 무반응이나 눈 감김을 응급 질환으로 단정하면 잘못된 경보와 신고로 이어질 수 있습니다. 그래서 화면 속 가상 감속, 정차, 응답 확인, 모의 SOS까지만 구현했습니다. 실제 차량 제어와 실제 119 신고는 하지 않습니다. 입력 정보만으로 의식 상실을 측정하는 기능이 있다고 발표하지 않으며, 시간 기준도 시연용으로 설명합니다.

근거: aura_safety_sim.py · Streamlit 시연



현재 카메라는 일반 RGB 웹캠이며 적외선 조명과 센서를 갖춘 야간 실차 검증은 수행하지 않았습니다. 공개 영상 일부를 처리했다고 해서 현재 장비의 야간 성능까지 검증한 것은 아닙니다. 선글라스도 착용 여부 라벨만으로 가려진 눈의 Open과 Closed를 알 수는 없습니다. 렌즈 뒤 눈 정보가 사라지면 확률 임계값을 낮춰도 복원되지 않습니다. 이런 경우는 관측 한계로 다뤄야 합니다. 현재 코드가 선글라스를 자동 식별하는 별도 모델을 갖춘 것은 아니며 향후 착용·가림 감지와 판단 보류 정책이 필요합니다.

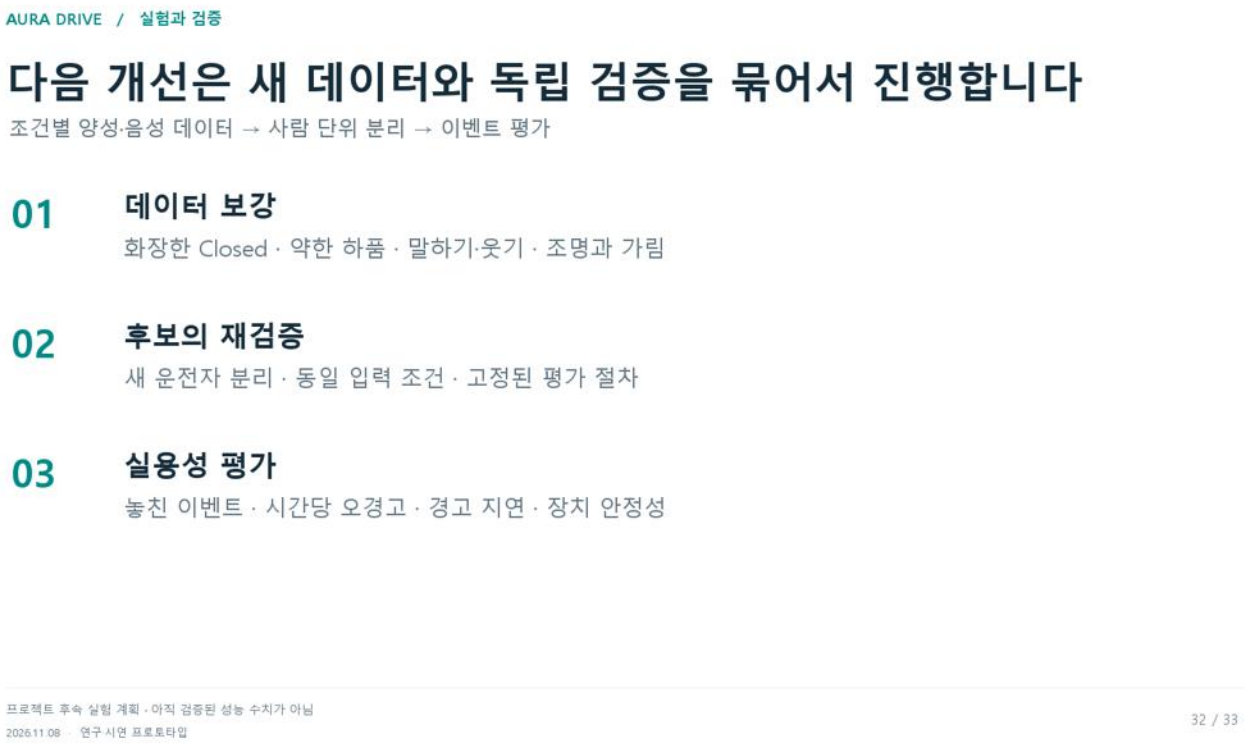
근거: 프로젝트 장비·데이터 범위 · Tesla 공식 제한사항 참고

발표 권장: 18~22분 · 실험 수치의 분모와 조건을 함께 설명



Tesla의 현행 일부 지역 Model 3 매뉴얼은 선글라스를 쓴 경우에도 운전자 주의 모니터링이 활성화된다고 설명합니다. 다만 같은 회사의 주의 분산 경고 제한사항에는 안경과 선글라스, 화장, 극단적인 조명, 적외선 조명 가림 등이 영향을 줄 수 있다고 명시돼 있습니다. 따라서 테슬라가 모든 선글라스 뒤 눈 감김을 완벽히 판별한다고 설명하면 안 됩니다. Fraunhofer 자료는 NIR과 RGB-IR, 센서 융합을 차량 실내 모니터링의 기술 방향으로 소개합니다. 우리 프로젝트에서는 향후 장비와 데이터 확장 가능성으로 제시합니다. 상세 원문 링크는 같은 폴더의 참고자료.md와 PPT의 출처 링크에 있습니다.

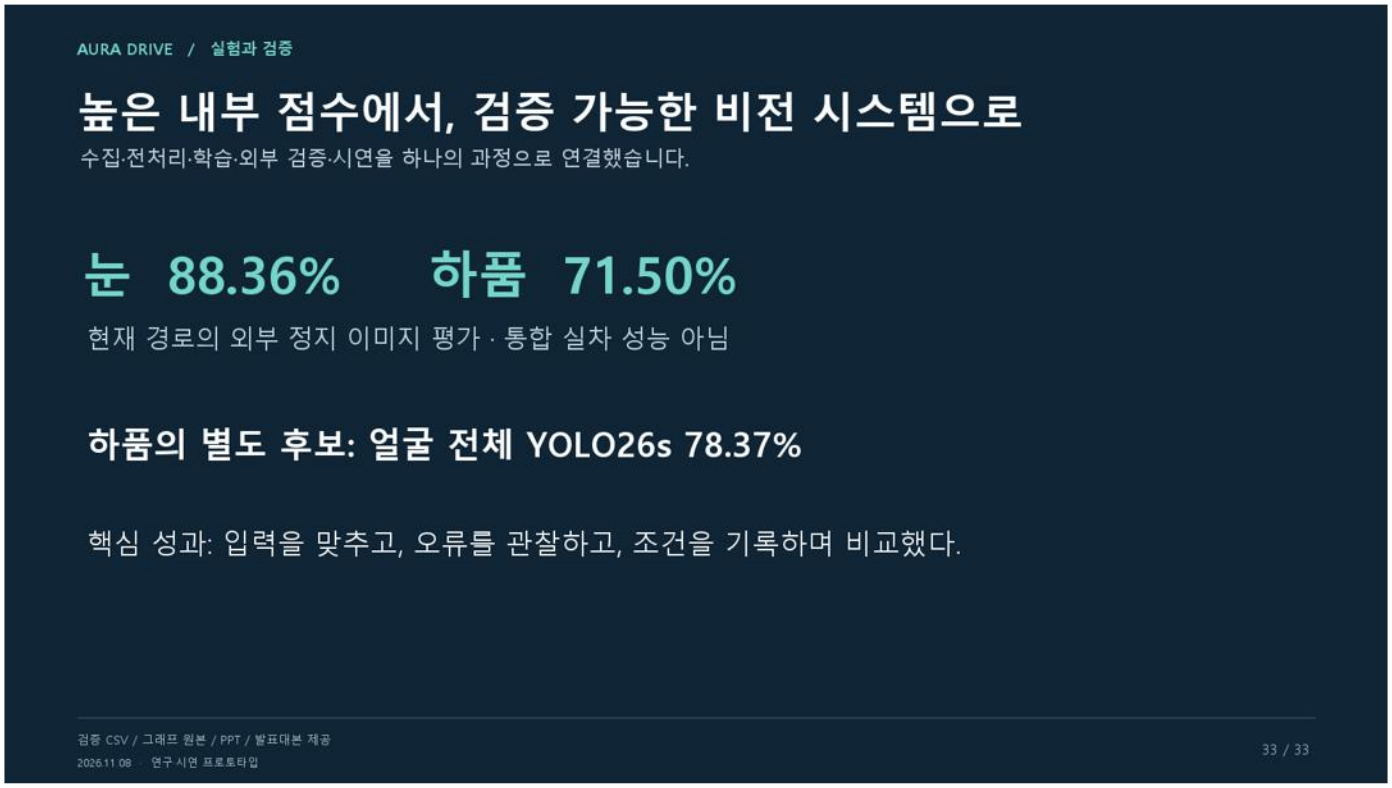
근거: Tesla Model 3 공식 매뉴얼 / Fraunhofer IOSB 백서 · 상세 링크는 발표대본



눈은 화장한 Open뿐 아니라 Closed, 안경과 가림 조건까지 균형 있게 확보해야 합니다. 하품은 약한 하품과 측면 하품, 말하기·웃기 같은 비하품을 함께 모아야 합니다. 같은 사람의 사진과 영상은 하나의 분할에 묶고 새로운 평가 자료는 모델과 임계값을 선택하기 전에 분리합니다. 이후 EAR·MAR 같은 랜드마크 지표와 입이 열리고 닫히는 지속 시간을 보조 정보로 비교할 수 있습니다. 마지막으로 정확도뿐 아니라 하품 이벤트 재현율, 시간당 오경고와 경고 지연을 측정하겠습니다. 이러한 후속 기능은 구현된 성과와 구분합니다.

근거: 프로젝트 후속 실험 계획 · 아직 검증된 성능 수치가 아님

발표 권장: 18~22분 · 실험 수치의 분모와 조건을 함께 설명



이 프로젝트는 눈과 하품을 각각 분류하는 데서 시작했습니다. 내부 점수만 보지 않고 직접 촬영 사진과 외부 데이터에서 실패 조건을 확인했습니다. 눈은 입력 부위를 맞추고 CLAHE와 임계값을 조정해 외부 성능을 개선했습니다. 하품은 낮은 외부 성능을 계기로 전처리와 판정 기준, 다른 모델과 입력 조합까지 비교했습니다. 현재 데모와 실험 후보를 구분했고, 야간·선글라스·응급 대응의 한계도 남겼습니다. 실용성은 가장 높은 숫자 하나가 아니라 새로운 사람에게 얼마나 덜 놓치고 덜 잘못 경고하는지로 평가하겠습니다.

근거: 검증 CSV / 그래프 원본 / PPT / 발표대본 제공

발표 권장: 18~22분 · 실험 수치의 분모와 조건을 함께 설명